逢甲大學 財務金融學系

115學年度

專題製作報告書

# AI選股結合ESG與現有ETF的比較


指導教授： 王鈺仁 老師

班　　級： 財金系 三年乙班

組　　長： 陳東杰 D1280673

組　　員： 陳亭翰 D1209072

陳治嘉 D1222280

黃彥霖 D1240092

張建民 D1240121


中華民國 115 年 5 月 18 日

# 致謝

感謝指導教授 王釭仁教授一年來的細心指導與教誨，並不時花費時間在觀念上進行討論，使本專題得以順利完成，且在報告撰寫過程中費心指出許多問題，讓報告的基礎得以成型，而不論在研究態度與待人接物方面均受益良多，並常提供一些日常生活中的經驗談，在此謹致上最誠摯之敬意與謝忱。

另外，特別感謝系上老師們的指導與鞭策。更有賴許多朋友在精神上給予鼓勵與支持，甚或實質協助，我們才能順利完成專題。

最後要感謝我們的父母與家人，若不是他們長久以來的支持，不可能有今天的小小成果，僅以此篇報告表達內心最誠摯的感激。

# 目錄

**第一章　緒論** ..... **1**

一、研究背景與動機 ..... 1

二、研究目的 ..... 2

三、研究問題與假說 ..... 2

四、驗證方式 ..... 3

**第二章　文獻回顧** ..... **4**

一、ESG 指標對企業績效之影響與預測路徑 ..... 4

二、傳統 ESG 共同基金與 ETF 之配置局限 ..... 4

三、AI 機器學習於選股領域之技術優勢 ..... 5

四、AI＋ESG 之整合應用與效率前緣實踐 ..... 5

五、文獻缺口 ..... 6

**第三章　研究方法** ..... **8**

一、樣本選擇、資料來源與對照基準 ..... 8

二、三種選股策略 ..... 9

三、研究流程架構 ..... 9

四、機器學習演算法 ..... 10

五、變數定義 ..... 11

六、訓練與測試：滾動式訓練（Walk-forward） ..... 12

七、投資組合建構與回測規則 ..... 12

八、績效評估方法 ..... 12

**第四章　實證結果** ..... **14**

一、整體績效比較 ..... 14

二、年度報酬 ..... 14

三、不同市場情境下的表現 ..... 15

四、統計檢定 ..... 15

五、模型診斷與獲利來源 ..... 16

六、換股與交易成本 ..... 16

七、穩健性測試 ..... 17

八、假說檢驗結果 ..... 18

**第五章　結論與建議** ..... **19**
一、研究發現 ..... 19
二、管理意涵 ..... 19
三、研究限制 ..... 19
四、未來研究方向 ..... 20
**參考文獻** ..... **21**
**附錄　研究平台說明** ..... **22**

# 第一章　緒論

## 一、研究背景與動機

隨著科技快速發展，人工智慧（AI）已從過去想像中的未來技術，逐漸成為推動現代社會與金融市場的重要核心力量。特別是在金融領域中，AI 憑藉其強大的非線性資料分析能力，正在逐步改變傳統投資決策模式。同時，全球資本市場也正在經歷一場從「追求獲利最大化」轉向「兼顧永續價值」的轉變。隨著氣候變遷、社會不平等及公司治理問題日益嚴重，投資人不再只關注企業短期財務績效，而是開始將環境（Environmental）、社會（Social）及公司治理（Governance）等 ESG 指標納入投資評估核心，希望透過永續投資降低長期風險並提升投資穩定性。

在這個趨勢下，ESG ETF（永續主題型指數股票型基金）快速崛起，例如「00878 國泰永續高股息」等產品受到市場高度關注，顯示出 ESG 投資已從過去的邊緣策略逐漸成為主流資產配置方式。ESG 投資能否真正有效預測企業未來報酬，仍是市場與學術界關注的重要問題。目前多數 ESG 評分主要依據企業所揭露的永續報告書、財務資訊及歷史數據進行評估，因此具有明顯的資訊滯後性（Lag Effect）。當企業營運狀況、市場環境或風險事件快速變化時，ESG 評分往往無法即時反映最新資訊，導致 ETF 成分股調整速度較慢。 此外，不同 ESG 評級機構對環境、社會及公司治理的衡量標準並不一致，可能造成同一企業在不同評級系統下出現截然不同的 ESG 分數，降低投資決策的可靠性。同時，部分企業可能透過資訊揭露包裝自身永續形象，而實際永續表現未必與評分結果相符，進一步產生「漂綠（Greenwashing）」問題。 因此，若只單純依賴 ESG 評分建立的 ESG ETF，可能會無法充分掌握市場即時資訊與企業未來發展趨勢，其投資績效及風險控制能力仍可有改善空間。

基於上述的問題，市場開始思考是否能透過更即時、更動態的技術改善傳統 ESG 投資模式，而人工智慧的發展則提供了一項新的可能性。傳統 ESG 評分主要依賴企業定期揭露的永續報告與歷史財務資料，屬於靜態且具時間落後的資訊來源；相較之下，AI 模型具備兩項重要優勢。首先是更新速度，AI 模型可以每天讀入最新的股價、成交量與估值資料，並定期重新訓練，快速反映市場的最新變化；其次是非線性關係學習能力，透過機器學習，AI 能找出技術面、估值與股價報酬之間複雜且非線性的關係，而這是傳統線性模型較難捕捉的。因此，AI 有機會降低 ESG 投資的資訊落後問題，並提升投資組合的選股效率。

綜合上述研究背景，本研究以「ESG 評分 → ESG ETF → AI 選股策略」作為核心研究脈絡，並自行建置一個每日自動更新的線上研究平台（ESG-AI 台股選股平台，https://esgaidashboard.streamlit.app）。平台整合台股 300 檔股票的股價、估值與 TEJ ESG 評等，以機器學習模型預測個股的短期相對報酬，建構「單純 AI」、「單純 ESG」與「AI+ESG」三種投資組合，並與加權指數及市售 ETF（0050、00850、

00878）在相同期間、扣除交易成本後進行比較，評估各策略在報酬率、風險控管與抗跌能力上的表現。

## 二、研究目的

基於近年 ESG 投資快速發展與人工智慧技術進步，本研究探討 ESG 指標與 AI 選股策略在台股投資上的有效性，並與現有 ESG ETF 比較，具體目的有三：

- **檢驗 ESG 評分的投資價值：**以 TEJ ESG 總分建構「單純 ESG」投組，觀察高 ESG 企業是否能帶來優於大盤的報酬，或主要提供較低風險。
- **檢驗 AI 能否提升 ESG 投資的效率：**以隨機森林（Random Forest）模型預測個股未來 10 個交易日的相對報酬，並將 AI 排名與 ESG 排名結合成「AI+ESG」投組，觀察報酬與風險的變化。
- **與市售 ETF 實際對標：**將三種投組與 0050、00850（元大臺灣ESG永續）、00878（國泰永續高股息）及加權指數比較，從報酬率、波動度、夏普值、最大回撤、Beta 與詹森 Alpha 評估是否具備超額報酬。

本研究希望透過上述三項目的，系統性檢視 ESG 指標之投資價值與 AI 技術在永續投資中的應用潛力，並以可重現、每日更新的線上平台呈現研究結果。

## 三、研究問題與假說

**表 1-1　研究問題與假說**

| 研究問題 (RQ) | 研究假說 (H) |
|---|---|
| RQ1　ESG 因子是否具有報酬預測能力？ | H1：ESG 評分較高之企業，其未來股票報酬優於大盤，ESG 可作為選股依據。 |
| RQ2　AI 是否能優化 ESG 選股策略？ | H2：結合 AI 預測的 AI+ESG 投組，報酬優於只依 ESG 評分選股的單純 ESG 投組。 |
| RQ3　AI-ESG 投組是否優於 ESG ETF？ | H3：AI+ESG 投組相對市售 ESG ETF（00850）及加權指數，具有正向且顯著的超額報酬（詹森 Alpha）。 |
| RQ4　不同市場環境下策略表現是否不同？ | H4：在多頭、急跌等不同市場環境下，各策略的相對表現不同；AI 策略在多頭期間較能捕捉動能，但在急跌期間的抗跌性需另行檢驗。 |

## 四、驗證方式

### （一）ESG 因子是否具有報酬預測能力？

以 TEJ ESG 總分由高到低選出前 20 檔（先排除爭議分數大於 3 與 EPS 為負的公司），每 10 個交易日重新調整，比較其與加權指數、00850 的年化報酬、Beta 與詹森 Alpha，並以每日報酬差的 t 檢定檢驗差異是否顯著。

### （二）AI 是否能優化 ESG 選股策略？

比較「單純 ESG」與「AI+ESG」（70% AI 預測排名＋30% ESG 排名）兩個投組在相同期間、相同交易成本下的累積報酬、夏普值與最大回撤；並以 Rank IC（預測排名與實際報酬排名的相關係數）檢驗 AI 模型本身是否具有選股能力。

### （三）AI-ESG 投組是否優於 ESG ETF？

以加權指數為市場基準，計算各投組的 Beta 與年化詹森 Alpha，並以日報酬迴歸檢驗 Alpha 的 t 值；同時與 0050、00850、00878 直接比較年化報酬、波動度、夏普值與最大回撤。

### （四）不同市場環境下策略表現是否不同？

依加權指數走勢切出多頭、急跌等子期間（例如 2025 年初的關稅衝擊下跌、2025 年 4 月起的多頭、2026 年 7 月的急跌），比較各策略的區間報酬與最大回撤；另計算上漲日與下跌日的「參與率」（策略平均報酬 ÷ 大盤平均報酬），衡量策略在漲時跟漲、跌時跟跌的程度。

# 第二章　文獻回顧

## 一、ESG 指標對企業績效之影響與預測路徑

在探討永續指標如何實質影響資產價格時，文獻展現出從單一正向關聯走向複雜非線性機制的論述演變。鄭雅萍（2025）針對台灣上市櫃公司的實證結果指出，企業的ESG表現與長期績效之間存在顯著的正向關聯，且在機器學習的分類框架下，公司治理（G）分數展現出最強的預測解釋力，這顯示出台灣投資市場對於企業經營透明度與風險控管的高度重視。

為了解明全球學術界過去數十年來的廣泛爭論，Friede et al. (2015) 透過整合全球超過 2,200 篇實證研究的巨量數據指出，ESG 投資的商業案例（Business Case）在經驗科學上具備極為堅實的基礎。該研究發現，高達 90% 的文獻呈現非負向（Non-negative）的 ESG 與財務績效關係，且絕大比例的研究報告了正向結果，此正向衝擊自 1990 年代中期以來更展現出長期的時間穩定性。

然而，更深層的資產定價理論則揭示了市場結構對報酬的制約。Pedersen et al. (2021) 透過理論模型與實證分析發現，ESG 對投資績效的影響並非單一方向，可能正向、負向或無顯著影響。該研究指出，當 ESG 資訊能有效預測企業未來獲利且市場尚未完全反映時，高 ESG 資產可能帶來超額報酬；但若市場中存在大量偏好 ESG 的投資人，資金過度追逐則會推高資產價格，導致未來的預期報酬率下降。此外，隨著研究深入到跨國大數據的檢驗，S&P 500 的實證研究（2025）進一步揭示了ESG與報酬之間呈現非線性的U型關係，回測中發現較寬鬆的 ESG 限制（例如在短期內適度納入低 ESG 企業）反而可能帶來更高報酬，這證實了「ESG 越高報酬越好」的單純線性假設在實際市場中仍有待商榷。

## 二、傳統 ESG 共同基金與 ETF 之配置局限

儘管永續投資已成為金融市場的主流趨勢，但傳統資產管理機構在實務操作上仍面臨諸多瓶頸。鄭雅萍（2025）在文獻評述中指出，雖然 ESG 評分已廣泛被用來評估企業的永續表現，但在實務應用上仍存在若干限制，包括不同評級機構之間的評分標準不一致會造成資訊解讀上的困難，且傳統投資分析方法多半假設變數之間為線性關係，難以完全挖掘金融市場中複雜且非線性的 ESG 潛在價值。

此外，這類傳統投資工具在面對市場變動時也缺乏足夠的穩健性。鄭雅萍（2025）進一步分析指出，傳統 ESG 基金高度依賴靜態的第三方 ESG 評分，這使得評分數據通常具有時間落後（lag）的問題，無法即時反映企業的最新狀況，且缺乏對即時市場事件或總體經濟變數的動態納入，導致模型在面對極端市場波動時的穩健性受到考驗。

Friede et al. (2015) 的大數據回測結果則精準解釋了為什麼許多投資人對實際投資績效抱持懷疑。該研究指出，相較於企業個體研究，傳統的「投資組合研究」（如 ESG 共同基金或指數型商品）其表現往往趨於中性或好壞參半。這主要是因為這類主動管理基金的績效容易被投資組合的系統性與特有風險所掩蓋，且往往受到高昂的「實施成本（Implementation Costs）」所侵蝕。在策略層面上，Pedersen et al. (2021) 亦提出警告，指出傳統基金若單純採用排除特定產業或低 ESG 股票的「排除篩選策略」，將會顯著降低投資組合的分散化效果與投資效率，甚至未必能實質提升整體的 ESG 表現。

## 三、AI 機器學習於選股領域之技術優勢

面對傳統線性模型的局限性，人工智慧與機器學習憑藉著優異的資料處理能力，為資產定價與個股預測帶來了技術突破。鄭雅萍（2025）主張，傳統的線性統計模型在處理環境（E）、社會（S）與公司治理（G）等高度非線性且具備交互作用的數據時，往往難以精準捕捉其對股價報酬的深層影響；而透過機器學習演算法對特徵空間的局部捕捉能力，能有效繞過傳統財務理論對常態分配的限制，進而在動態變化的股市中尋找具備超額報酬的投資組合。

Friede et al. (2015) 透過區域與資產類別的細分研究，進一步為數據挖掘的方向提供了實證指引。他們發現 ESG 的超額報酬機會在不同市場具備高度異質性，例如新興市場（Emerging Markets）相較於歐美發達市場，展現出顯著更高比例的正向財務回報（未剔除投資組合研究前高達 65.4%）。這顯示在資訊不對稱性較高的市場或非權益類資產中，高維度數據的潛在價值更為龐大，這恰好為 AI 演算法提供了極佳的特徵學習與選股溢價空間。

隨著演算法的演進，AI選股的應用已從基礎分類模型邁向更具魯棒性的集成學習架構。S&P 500 的實證研究（2025）指出，人工智慧與機器學習被廣泛應用於選股領域，核心在於從市場中篩選出具備潛力的個股進行排序，而非僅預測整體市場報酬。該研究採用 CatBoost 回歸模型預測個股未來30天的報酬率，結合細分的 ESG 風險指標與股價資料建構動態投資組合，並透過時間序列切分等資料前處理程序避免過度擬合（Overfitting）。這種結合機器學習排序能力與動態投資組合管理的架構，顯著優於傳統的線性預測模型。

## 四、AI＋ESG 之整合應用與效率前緣實踐

將 AI 技術與 ESG 指標深度整合，被視為在永續發展與投資報酬之間取得最佳平衡的關鍵路徑。在理論架構上，Pedersen et al. (2021) 提出了「ESG效率前緣（ESG-efficient frontier）」的概念，說明投資人需在風險、報酬與ESG之間進行權衡，此架構

描述了在不同 ESG 水準下投資人可達達到最佳夏普值（Sharpe Ratio），將 ESG 成功融入了傳統的資產配置理論中。

在實證績效與策略實踐上，這種結合AI的動態配置展現出顯著的優越性。鄭雅萍（2025）利用K-近鄰演算法（KNN）與分類迴歸樹（CTree）建構的模擬投資組合，實證結果顯示，應用ESG資料作為特徵輸入進行AI選股時，其整體績效與年化報酬率能穩定優於以ESG為投資目標的傳統共同基金與大盤基準。

與此同時，Friede et al. (2015) 的結論也為這種 AI 驅動的整合指明了必然趨勢：理性的投資人為了履行受託人職責（Fiduciary Duties），必須將 ESG 標準納入投資流程，而這需要對如何「整合（Integrate）」ESG 準則有更深刻且量化的理解。同樣地，S&P 500 的實證研究（2025）亦證實，結合 CatBoost 回歸模型與細分 ESG 風險指標的選股策略，在風險調整後績效上成功產生了顯著的超額報酬（Alpha），且該模型具備高度彈性，可依投資人的風險偏好靈活調整 ESG 門檻。這些研究共同證明了，傳統基金因成本與線性限制而無法獲取的永續溢價，透過 AI 選股模型進行動態管理，能夠有效在「永續性」與「獲利性」之間取得最佳平衡。

## 五、文獻缺口

綜合上述國內外文獻可以發現，儘管現有研究已證實 ESG 指標、機器學習與投資績效之間存在緊密關聯，但在實務應用與研究設計上仍存在顯著的優化空間。現行的 ESG ETF 與傳統永續基金，在操作上大多仍受限於被動式投資架構，高度依賴第三方評級機構進行半年或季度的定期審查。這種靜態篩選機制不可避免地帶來了資訊滯後（lagging）的弊端，導致投資組合難以在第一時間反映企業的突發性爭議事件或劇烈的市場波動，在動態風險管理上顯得相對被動。

與此同時，現階段的 AI 選股研究雖在預測能力上普遍優於傳統線性模型，但其模型輸入特徵仍高度集中於財務因子、技術指標或歷史價格，鮮少將 ESG 等非財務資訊深度融入核心演算法中。這種現象導致人工智慧的技術優勢與永續投資理念在實務上產生了斷裂，模型往往難以在追求超額報酬與實踐永續價值之間取得最佳平衡點。

即便近期有少數前沿研究嘗試結合兩者以建立動態選股策略，但在實證層面仍面臨多重限制。多數研究在驗證績效時，往往僅與理論基準或傳統大盤指數進行對比，缺乏與市場上實際運行且具代表性的 ESG ETF 進行直接的「壓力測試」，因而難以證實其在真實交易環境中的相對優勢。此外，相關實證多聚焦於美國等成熟市場，對台灣股市的探討仍顯不足。鑑於台股具備產業集中度高（如半導體權值股比重過大）以及散戶參與度高等獨特生態，既有的國外研究結論未必能完全複製。更重要的是，現有模型大多忽略了市場狀態（Regime）切換對因子有效性的衝擊，未充分考慮 ESG 因

子在多頭、空頭或高波動等不同總體經濟環境下的表現差異，使模型的穩健性留有盲點。

鑑於上述研究限制，本研究整合機器學習模型與 ESG 評級指標，建構每 10 個交易日調整一次的動態選股策略，以台灣股市為實證對象，直接與市售 ESG ETF 進行績效對標，並以不同市場情境的子期間檢驗策略穩健性，期盼能在「動態調整機制」、「台股市場實證」以及「真實投資工具對標」等面向補足現有文獻。

# 第三章　研究方法

## 一、樣本選擇、資料來源與對照基準

本研究以台灣上市櫃普通股為母體，從中選出最近 20 個交易日平均成交金額最大的 300 檔股票作為股票池（市值前 50 大一定納入），兼顧流動性與選股範圍。資料由研究平台每日自動更新，來源如下：

**表 3-1　資料來源**

| 資料 | 來源 | 頻率／期間 | 用途 |
|---|---|---|---|
| 股價、成交量（還原權息） | Yahoo Finance | 每日；2017-08 起 | 技術面特徵、報酬計算 |
| 本益比、股價淨值比、殖利率 | 臺灣證券交易所 | 每月底；2017-08 起（僅上市） | 估值特徵 |
| 成交金額 | 證交所、櫃買中心 | 每日 | 挑選 300 檔股票池 |
| ESG 評等（總分、E／S／G、爭議分數） | TEJ 台灣經濟新報 TESG | 半年一期，共 8 期；最早公告 2022-11-01 | ESG 選股與排除條件 |
| 比較基準 | Yahoo Finance | 每日 | 加權指數、0050、00850、00878 |

所有資料一律依「公告日」對齊：某一天只會用到當天以前已經公布的資料，避免在回測中用到未來資訊（前視偏差）。模型的訓練資料從 2017 年 8 月開始；樣本外績效則從 2022 年 11 月 1 日（TEJ ESG 評等第一次公告）開始計算，使三種策略在相同的起點、都有 ESG 資料的條件下進行比較。樣本外期間為 2022-11-01 至 2026-10-19，共約 3.9 年、96 次調倉。

**表 3-2　比較基準**

| 對照基準 | 代表意義 |
|---|---|
| 加權指數（^TWII） | 台股大盤，作為計算 Beta 與詹森 Alpha 的市場基準 |
| 0050 元大台灣50 | 市值型 ETF，代表一般被動投資 |
| 00850 元大臺灣ESG永續 | ESG 型 ETF，直接對標「單純 ESG」與「AI+ESG」 |
| 00878 國泰永續高股息 | ESG＋高股息 ETF，代表防禦型的永續投資 |

## 二、三種選股策略

三種策略每次都從 300 檔股票池中選出 20 檔、每檔 5% 等權持有，差別只在「排序依據」：

**表 3-3　三種選股策略**

| 策略 | 排序依據 | 代表的投資理念 | 對標 |
|---|---|---|---|
| 單純 AI | AI 模型預測的未來 10 日相對報酬 | 完全追求報酬最大化的高動能策略 | 0050、加權指數 |
| 單純 ESG | TEJ ESG 總分（先排除爭議分數 > 3、EPS < 0） | 規則式 ESG 篩選，模擬市售 ESG ETF 的建構方式 | 00850 |
| AI+ESG | 70% × AI 預測排名 ＋30% × ESG 排名（同樣先排除爭議、虧損公司） | 在獲利性與永續性之間取得平衡 | 00850、00878 |

選擇 20 檔，是為了兼顧風險分散與報酬集中：持股太少，單一股票出事影響太大；持股太多，則會稀釋模型的選股效果。穩健性測試（第四章第七節）也顯示，等權持有 15～30 檔的結果相近。選股時不限制同一產業的檔數，也不排除任何產業，只要個股分數夠高就會入選。

## 三、研究流程架構

1. **資料蒐集與更新：**研究平台每個交易日收盤後自動抓取股價、成交量、比較基準、估值與三大法人資料，並讀入 TEJ ESG 評等。
2. **建立股票池：**依最近 20 個交易日平均成交金額，挑出前 300 檔上市櫃普通股。
3. **特徵工程：**為每檔股票、每一天計算 14 個特徵（技術面、見頂訊號、估值），ESG 與估值依公告日對齊。
4. **AI 模型滾動訓練：**以隨機森林學習「特徵 → 未來 10 日相對報酬」，每 3 次調倉重新訓練一次，只使用訓練當天已知結果的資料。
5. **ESG 排除與排序：**排除爭議分數大於 3 及 EPS 為負的公司，再依三種策略各自的分數排序。
6. **建構投資組合：**每 10 個交易日，各策略選出前 20 檔、等權持有。
7. **回測與交易成本：**以調倉日收盤價換股、隔日起算報酬，買進扣手續費 0.1425%，賣出扣手續費 0.1425% 與證交稅 0.3%。

8. **績效比較：**與加權指數、0050、00850、00878 比較報酬、風險與風險調整後績效，並計算 Beta 與詹森 Alpha。

9. **市場情境與統計檢定：**切分多頭、急跌等子期間，並以迴歸與 t 檢定檢驗超額報酬是否顯著。

10. **穩健性測試與獲利來源分析：**更換模型、持股數、權重方式、調倉頻率、隨機種子與特徵組合，並以特徵重要性與 Rank IC 分析獲利來源。

## 四、機器學習演算法

本研究以隨機森林（Random Forest）作為主要模型，另以 XGBoost 及兩者平均（Ensemble）進行比較。

### （一）Random Forest（隨機森林）

Random Forest 是一種基於集成學習（Ensemble Learning）的方法，其核心思想是「多模型投票決策」。模型透過 Bootstrap 隨機抽樣生成多組訓練資料，並在每一棵決策樹的分裂過程中隨機選取部分特徵進行建構，使每一棵樹都具有差異性。最後，模型會將所有樹的結果進行平均（回歸問題）或投票（分類問題），作為最終預測結果。

由於Random Forest不依賴單一決策樹，因此具有較高的穩定性與抗過度擬合能力，即使在資料含有雜訊或變數高度相關的情況下，仍能維持穩定表現。同時，它也具備良好的解釋能力，可以透過特徵重要性（Feature Importance）評估各因子對結果的影響程度。在本研究中，Random Forest 不僅用於預測股票報酬，也有助於分析 ESG 與財務因子在投資決策中的相對重要性。

本研究的隨機森林由 100 棵決策樹組成，每棵樹最多 6 層、每個葉節點至少 20 筆樣本、每次分裂隨機使用 70% 的特徵、每棵樹隨機抽取 50% 的樣本，以限制模型複雜度、避免背誦歷史資料。

### （二）XGBoost（Extreme Gradient Boosting）

XGBoost 是一種以梯度提升樹（Gradient Boosting Decision Tree, GBDT）為基礎的機器學習方法，其核心概念在於「逐步修正錯誤」。模型會依序建立多棵決策樹，每一棵新樹都專門學習前一輪模型的殘差（prediction error），並透過加總方式逐步優化整體預測結果。由於這種逐步逼近真實值的方式，XGBoost 能有效捕捉資料中的非線性關係與複雜交互作用，特別適合金融市場這類多因子且關係不穩定的資料結構。

在本研究的比較中，XGBoost 與 Ensemble 的回測報酬都明顯低於隨機森林（見第四章第七節），因此最終採用隨機森林。可能原因是股票報酬的雜訊很大，XGBoost 逐步修正殘差的特性較容易學到雜訊，而隨機森林以多棵樹平均的方式較為穩定。

## 五、變數定義

### （一）Y 變數：模型的預測目標

本研究將問題設定為迴歸（Regression）問題：預測每檔股票「未來 10 個交易日的報酬率，減去同一天全部股票的平均報酬率」，也就是「比其他股票多賺多少」。

採用相對報酬而非絕對報酬，是因為模型的任務是排序股票、挑出相對強勢者，而非預測大盤漲跌；把大盤的共同漲跌扣掉後，模型可以專注在個股之間的差異。預測期間設為 10 個交易日，與調倉頻率一致。

### （二）X 變數：輸入模型的特徵

**表 3-4　模型特徵（共 14 個）**

| 類別 | 特徵 | 計算方式 | 衡量什麼 |
|---|---|---|---|
| 技術面 | 近 5／20／60 日報酬 | 今日收盤價 ÷ N 日前收盤價 − 1 | 短、中期動能 |
| 技術面 | 20 日年化波動率 | 近 20 日日報酬標準差 × √252 | 股價震盪程度 |
| 技術面 | 月線乖離率 | 收盤價 ÷ 20 日均價 − 1 | 是否偏離短期成本 |
| 技術面 | 季線乖離率 | 收盤價 ÷ 60 日均價 − 1 | 是否偏離中期成本 |
| 見頂訊號 | 距 20 日最高價跌幅 | 收盤價 ÷ 近 20 日最高價 − 1 | 已從高點回落多少 |
| 見頂訊號 | 距 20 日最高價天數 | 近 20 日最高價是幾天前 | 漲勢停了多久 |
| 見頂訊號 | 連續下跌天數 | 連續收黑的天數 | 跌勢延續程度 |
| 見頂訊號 | 量能比 | 近 5 日均量 ÷ 近 60 日均量 | 放量或量縮 |
| 見頂訊號 | 短期反轉 | 近 5 日報酬 × 近 60 日報酬 | 大漲後是否短線轉弱 |
| 估值 | 本益比、股價淨值比、殖利率 | 證交所每月底資料（上櫃股以中位數代替） | 價格是否便宜 |

「見頂訊號」用來區分「還在上漲的強勢股」與「已經從高點回落的強勢股」；加入後，2018 年起約 8 年的回測中單純 AI 年化報酬由約 100% 提高到約 106%。ESG 分數不放入 AI 模型，而是在選股階段才與 AI 排名結合，以便分別觀察 AI 與 ESG 各自的貢獻。

## 六、訓練與測試：滾動式訓練（Walk-forward）

金融資料具有時間順序，若隨機切分訓練集與測試集，會用到未來資訊。本研究採用擴展視窗的滾動式訓練：

- **訓練集：**從 2017 年 8 月起、到訓練當天往前 10 個交易日為止的所有「股票 × 日期」樣本（每 5 個交易日取一天），配上已實現的未來 10 日相對報酬。最後 10 天的報酬在訓練當天還不知道，因此不能使用。
- **測試集：**調倉當天全部股票的最新特徵，由模型輸出預測分數，用來選股。
- **重新訓練：**每 3 次調倉（約 30 個交易日）重新訓練一次，把新揭曉結果的資料加入訓練集。樣本外期間共訓練 33 次，訓練樣本從約 6.6 萬筆增加到約 12.2 萬筆。
- **缺值處理：**以訓練集的中位數補值，不使用測試期資訊。

## 七、投資組合建構與回測規則

**表 3-5　回測規則**

| 項目 | 設定 |
|---|---|
| 調倉頻率 | 每 10 個交易日，以調倉日收盤價換股，報酬從下一個交易日開始計算 |
| 持股 | 各策略分數最高的 20 檔，每檔 5%（等權）；持有期間權重隨股價自然變動 |
| 產業 | 不限制同一產業檔數、不排除任何產業 |
| 交易成本 | 買進手續費 0.1425%；賣出手續費 0.1425% ＋ 證交稅 0.3%；每次換股都扣除 |
| 資金運用 | 永遠滿倉，不設停損、不因大盤轉弱而減碼（以報酬最大化為目標） |
| 樣本外期間 | 2022-11-01 ～ 2026-10-19，共 96 次調倉 |

## 八、績效評估方法

本研究從獲利、風險、風險調整後報酬與相對市場的超額報酬四個面向評估策略績效：

**表 3-6　績效指標**

| 指標 | 定義 | 解讀 |
|---|---|---|
| 累積報酬率 | 每日報酬連乘：$\Pi(1+r_t)-1$ | 整段期間總共賺多少 |

| 指標 | 定義 | 解讀 |
|---|---|---|
| 年化報酬率 | (1＋累積報酬)^(252 ÷ 交易日數) − 1 | 平均每年賺多少（幾何年化） |
| 年化波動率 | 日報酬標準差 × √252 | 報酬上下震盪的幅度 |
| 夏普值（Sharpe） | (年化報酬 − 無風險利率 1%) ÷ 年化波動 | 每承擔一單位風險換到多少報酬；大於 1 佳、大於 2 極佳 |
| 最大回撤（MDD） | 淨值從歷史高點跌到低點的最大幅度 | 最糟情況下可能虧多少 |
| Beta | 策略日超額報酬對大盤日超額報酬的迴歸斜率 | 跟著大盤漲跌的程度 |
| 詹森 Alpha | 年化報酬 − [1% ＋ Beta × (大盤年化報酬 − 1%)] | 扣掉承擔大盤風險本來就該賺的之後，多賺的部分 |
| Rank IC | 每次調倉時，預測排名與實際 10 日報酬排名的相關係數 | 模型選股能力；平均 0.03～0.05 即具實用價值 |

# 第四章　實證結果

以下結果皆取自研究平台（樣本外期間 2022-11-01 ～ 2026-10-19，已扣除交易成本）。

## 一、整體績效比較

**表 4-1　樣本外績效（2022-11-01 ～ 2026-10-19）**

| 投組 | 累積報酬 | 年化報酬 | 年化波動 | Sharpe | 最大回撤 | Beta | 詹森 Alpha |
|---|---|---|---|---|---|---|---|
| 單純 AI | 1,897.8% | 119.7% | 39.4% | 3.01 | −46.2% | 1.19 | 72.5% |
| AI+ESG | 794.7% | 77.9% | 35.7% | 2.15 | −41.0% | 1.20 | 30.0% |
| 單純 ESG | 304.8% | 44.4% | 19.7% | 2.21 | −23.8% | 0.79 | 12.5% |
| 0050 元大台灣50 | 382.8% | 51.2% | 24.2% | 2.08 | −27.5% | 1.06 | 9.2% |
| 00850 元大臺灣ESG永續 | 330.9% | 46.7% | 22.1% | 2.07 | −26.9% | 0.97 | 7.9% |
| 00878 國泰永續高股息 | 207.9% | 34.3% | 16.9% | 1.98 | −22.3% | 0.64 | 8.4% |
| 加權指數 | 259.1% | 39.9% | 22.1% | 1.76 | −28.7% | 1.00 | 0.0% |

單純 AI 的年化報酬 119.7%、夏普值 3.01 都是所有投組中最高，但最大回撤 −46.2% 也最深；AI+ESG 年化 77.9%，報酬高於所有 ETF，波動與回撤介於單純 AI 與 ETF 之間；單純 ESG 年化 44.4%，略低於 0050、與 00850 相近，但 Beta 只有 0.79、最大回撤 −23.8%，表現出明顯的防禦性。

## 二、年度報酬

**表 4-2　各年度報酬**

| 年度 | 單純 AI | AI+ESG | 單純 ESG | 0050 | 00850 | 00878 | 加權指數 |
|---|---|---|---|---|---|---|---|
| 2022（11～12 月） | 7.2% | 3.8% | 6.7% | 10.6% | 9.0% | 4.1% | 8.4% |
| 2023 | 120.4% | 81.7% | 53.7% | 27.5% | 30.0% | 43.8% | 26.8% |
| 2024 | 126.6% | 51.2% | 7.9% | 48.6% | 37.1% | 11.2% | 28.5% |
| 2025 | 91.7% | 78.6% | 21.5% | 36.9% | 27.9% | 6.3% | 25.7% |
| 2026（至 10/19） | 94.6% | 75.6% | 88.2% | 68.2% | 73.7% | 74.0% | 61.7% |

完整年度中，單純 AI 每年都贏過加權指數與三檔 ETF；AI+ESG 在 2023、2025 年明顯領先，2024 年則與 0050 相近；單純 ESG 在 2023 年表現佳，2024 年僅 7.9%，明顯落後大盤，顯示 ESG 評分的報酬貢獻並不穩定。

## 三、不同市場情境下的表現

**表 4-3　子期間區間報酬**

| 期間 | 單純 AI | AI+ESG | 單純 ESG | 0050 | 00850 | 00878 | 加權指數 |
|---|---|---|---|---|---|---|---|
| 2025/1/2～4/9 關稅衝擊下跌 | −35.0% | −30.6% | −19.4% | −24.3% | −24.0% | −18.0% | −24.5% |
| 2025/4/10～2026/6/10 多頭 | 533.7% | 376.7% | 136.0% | 180.1% | 168.0% | 96.6% | 148.5% |
| 2026/6/11～7/31 急跌 | −27.9% | −15.5% | 6.2% | 3.2% | −0.3% | 2.6% | −0.2% |

**表 4-4　上漲日／下跌日參與率（策略平均日報酬 ÷ 大盤平均日報酬）**

| 投組 | 上漲日參與率 | 下跌日參與率 | 解讀 |
|---|---|---|---|
| 單純 AI | 1.38 | 1.02 | 大盤上漲時多漲 38%，下跌時跌幅約與大盤相同 |
| AI+ESG | 1.32 | 1.16 | 漲時多漲 32%，但跌時也多跌 16% |
| 單純 ESG | 0.85 | 0.77 | 漲跌都比大盤小，跌時更明顯，具防禦性 |

在多頭期間，AI 策略的報酬遠高於 ETF；但在急跌期間（2025 年初的關稅衝擊、2026 年 7 月），單純 AI 與 AI+ESG 都跌得比 ETF 深，單純 ESG 則明顯抗跌（2026 年 7 月甚至上漲 6.2%）。原因是 AI 模型偏好近期動能強、波動大的股票，這類股票在急跌時往往跌最兇。由此可知，AI 策略的超額報酬主要來自多頭期間，並非來自較佳的抗跌能力。

## 四、統計檢定

**表 4-5　超額報酬的統計檢定（日報酬，2022-11-01 ～ 2026-10-19）**

| 投組 | 日 Alpha | Alpha t 值 | Beta | 相對 00850 每日超額 | t 值 | 相對大盤每日超額 | t 值 |
|---|---|---|---|---|---|---|---|
| 單純 AI | 0.174% | 2.90 | 1.19 | 0.181% | 2.96 | 0.201% | 3.33 |
| AI+ESG | 0.082% | 1.69 | 1.20 | 0.092% | 1.84 | 0.111% | 2.25 |
| 單純 ESG | 0.039% | 2.12 | 0.79 | −0.009% | −0.43 | 0.010% | 0.49 |

以 5% 顯著水準（$|t| > 1.96$）判斷：單純 AI 的 Alpha 與相對 00850、大盤的超額報酬都顯著；AI+ESG 相對大盤的超額報酬顯著，但 Alpha 與相對 00850 的超額報酬只達 10% 顯著水準；單純 ESG 的 Alpha 顯著為正（主要來自低 Beta），但與 00850、大盤的每日報酬差異不顯著。

## 五、模型診斷與獲利來源

**表 4-6　AI 模型選股能力**

| 指標 | 數值 | 說明 |
|---|---|---|
| 平均 Rank IC | 0.026 | 預測排名與實際排名呈正相關 |
| Rank IC 大於 0 的比例 | 61.1% | 95 次可評估的調倉中，約六成排得比亂猜好 |
| Rank IC 的 t 值 | 1.82 | 接近 5% 顯著水準 |
| 前 20 檔平均超額報酬（每期） | 1.83% | 模型選的前 20 檔，每 10 天平均比全部股票多賺 1.83%（未扣成本） |
| 超額報酬為正的期數比例 | 67.4% | 約三分之二的期間選股贏過平均 |

**表 4-7　特徵重要性（最近一次訓練，前 10 名）**

| 排名 | 特徵 | 重要性 |
|---|---|---|
| 1 | 20 日年化波動率 | 32.8% |
| 2 | 季線乖離率 | 11.4% |
| 3 | 近 1 月報酬（動能） | 10.1% |
| 4 | 月線乖離率 | 9.4% |
| 5 | 近 3 月報酬（動能） | 8.5% |
| 6 | 近 5 日報酬 | 5.6% |
| 7 | 量能比 | 4.7% |
| 8 | 短期反轉 | 4.6% |
| 9 | 股價淨值比 | 4.0% |
| 10 | 距 20 日最高價跌幅 | 3.9% |

模型最依賴的是波動率與動能類特徵，估值特徵的影響較小。這說明 AI 策略的獲利主要來自「捕捉強勢、高波動股票的延續上漲」，與表 4-3 中多頭期間大幅領先、急跌期間跌幅較深的結果一致。

## 六、換股與交易成本

**表 4-8　換股與成本**

| 投組 | 調倉次數 | 平均週轉率 | 累計交易成本 |
|---|---|---|---|
| 單純 AI | 96 | 63.8% | 35.7% |

| 投組 | 調倉次數 | 平均週轉率 | 累計交易成本 |
|---|---|---|---|
| AI+ESG | 96 | 52.2% | 29.2% |
| 單純 ESG | 96 | 4.1% | 2.2% |

AI 策略每次調倉約換掉一半以上的持股，約 4 年累計付出約 30% 的交易成本；以上績效皆已扣除這些成本。單純 ESG 因 ESG 評分半年才更新一次，持股幾乎不變，交易成本極低。

## 七、穩健性測試

為避免結果只是某一組參數的巧合，本研究在研究平台上進行以下比較（皆以 3 組隨機種子重跑，除特別註明外）：

**表 4-9　穩健性測試摘要**

| 測試項目 | 比較內容 | 結果（單純 AI 年化報酬） | 結論 |
|---|---|---|---|
| AI 模型 | Random Forest／XGBoost／Ensemble | Random Forest 最佳，其餘明顯較低 | 採用 Random Forest |
| 持股數與權重 | Top 10～30；等權／集中加權 | 等權 Top 10～30 約 116%～126%；集中加權約 90% | 結果對持股數不敏感；採等權 Top 20 |
| 調倉頻率 | 每月 vs. 每 10 個交易日 | 約 108% → 約 119% | 採每 10 個交易日 |
| 重新訓練頻率 | 每 3 次 vs. 每 6 次調倉 | 每 3 次高約 10 個百分點 | 採每 3 次 |
| 見頂訊號特徵 | 加入與否（2018 年起 8 年） | 約 100% → 約 106% | 採用 |
| 產業納入方式 | 產業特徵／只買趨勢向上產業／同產業上限 5 檔（8 年） | 約 85%／約 78%／約 105%（不納入約 106%） | 皆未提升報酬，不採用 |
| 產業趨勢加分 | 產業近 1 月報酬排名權重 0%／5%／10%／20%（8 年，1 組種子） | 約 110%／104%／98%／85% | 越加越差，不採用 |

各項測試中，策略在不同持股數、隨機種子下的結果都相近，且在包含 2020 年疫情崩跌與 2022 年空頭的 8 年期間仍維持高於大盤的報酬，顯示 AI 選股的效果並非單一參數的巧合。值得注意的是，四種把產業趨勢納入選股的做法都沒有提升報酬：強勢個股常在產業轉強之前就先上漲，等產業趨勢確認時已偏晚，而過去一個月最強的產業也常出現漲多拉回。

## 八、假說檢驗結果

**表 4-10　假說檢驗摘要**

| 假說 | 結果 | 依據 |
|---|---|---|
| H1　ESG 評分較高之企業報酬優於大盤 | 部分支持 | 單純 ESG 年化 44.4% 高於大盤 39.9%、Alpha 顯著，但與大盤、00850 的報酬差異不顯著；主要價值在於低 Beta、低回撤的防禦性 |
| H2　AI+ESG 報酬優於單純 ESG | 支持（報酬） | 年化 77.9% vs. 44.4%；但夏普值相近（2.15 vs. 2.21）、回撤較深，報酬提升伴隨風險上升 |
| H3　AI+ESG 相對 ESG ETF 有顯著超額報酬 | 部分支持 | 相對大盤顯著（t = 2.25）；Alpha 與相對 00850 僅達 10% 顯著水準。單純 AI 則全部顯著 |
| H4　不同市場環境下表現不同 | 支持 | 多頭期間 AI 策略大幅領先；急跌期間 AI 策略跌幅最深、單純 ESG 最抗跌 |

# 第五章　結論與建議

## 一、研究發現

- **AI 選股具有顯著的超額報酬：**單純 AI 投組在樣本外約 4 年、扣除交易成本後年化 119.7%，詹森 Alpha 72.5%（t = 2.90），每個完整年度都贏過大盤與三檔 ETF。
- **ESG 評分的價值偏向風險控制：**單純 ESG 的報酬與 00850 相近，但 Beta 僅 0.79、最大回撤最小，在急跌期間明顯抗跌。
- **AI＋ESG 在報酬與永續之間取得折衷：**AI+ESG 報酬高於所有 ETF，且持股兼顧 ESG 評等，但抗跌性不如 ESG ETF。
- **AI 的超額報酬主要來自多頭期間：**模型偏好高動能、高波動股票，在多頭時大幅領先，在急跌時跌幅較深。

## 二、管理意涵

- 投資人可依風險承受度選擇：追求最高報酬者適合單純 AI；希望兼顧永續與報酬者適合 AI+ESG；重視穩定與抗跌者，ESG ETF 或單純 ESG 投組較合適。
- ESG ETF 的被動篩選方式雖然報酬未必最高，但在市場急跌時提供明顯的保護，適合作為核心持股；AI 策略則較適合作為衛星配置。
- AI 策略換股頻繁、交易成本高，實務上需考量成本與滑價；本研究已將手續費與證交稅納入計算。

## 三、研究限制

- **存活者與前視偏差：**股票池以「目前」的成交金額挑選，過去已下市或曾經熱門的股票不在其中，回測績效可能偏樂觀。
- **樣本外期間較短、以多頭為主：**2022-11 至 2026-10 約 4 年，主要為 AI 與電子股多頭；預設參數也在同期資料上比較選出，未來報酬很可能低於回測。
- **ESG 資料期數有限：**TEJ ESG 評等自 2022-11 起僅 8 期、半年更新一次，難以檢驗 ESG 的長期預測力。
- **未考慮滑價與資金容量：**以收盤價成交為假設；上櫃股缺少估值資料，以中位數代替。
- **部分原規劃方法尚未實作：**Sortino 比率、Fama-French 五因子歸因、以隱藏馬可夫模型（HMM）辨識市場狀態、最小變異數權重等，本研究以子期間比較與詹森 Alpha 代替，留待後續研究。

## 四、未來研究方向

- 以 Fama-French 五因子模型拆解 AI 策略的報酬來源，確認超額報酬是否來自動能、規模等風格因子。
- 加入市場狀態辨識（例如 HMM 或大盤均線），在空頭時降低持股，改善 AI 策略的抗跌性。
- 納入新聞、財報與 ESG 爭議事件等即時資訊，以自然語言處理補足 ESG 評分的時間落差。
- 使用包含已下市股票的歷史成分股資料，消除存活者偏差，並延長樣本外期間。

# 參考文獻

鄭雅萍（2025）。機器學習下 ESG 選股之投資績效探討〔碩士論文，國立勤益科技大學〕。臺灣博碩士論文知識加值系統。https://hdl.handle.net/11296/m62b99

Friede, G., Busch, T., & Bassen, A. (2015). ESG and financial performance: aggregated evidence from more than 2000 empirical studies. Journal of Sustainable Finance & Investment, 5(4), 210-233. https://www.tandfonline.com/doi/full/10.1080/20430795.2015.1118917

Pedersen, L. H., Fitzgibbons, S., & Pomorski, L. (2021). Responsible investing: The ESG-efficient frontier. Journal of Financial Economics, 142(2), 572-597. https://www.sciencedirect.com/science/article/pii/S0304405X20302853

S&P 500 ESG AI Selection Research (2025). https://www.sciencedirect.com/science/article/pii/S1062940825001573

# 附錄　研究平台說明

本研究所有數據與圖表皆來自自行開發的「ESG-AI 台股選股平台」（https://esgaidashboard.streamlit.app），程式碼公開於 GitHub（Hendrick0815/ESG_AI_Dashboard），每個交易日收盤後自動更新資料並重新計算回測。

**表 A-1　平台功能**

| 頁面 | 主要內容 |
|---|---|
| 首頁 | 三種策略最新的選股名單、年化報酬與累積淨值 |
| 策略回測 | 績效比較（可選期間、對數刻度）、歷次持股與持有期間預估走勢、換股與成本、方法說明 |
| 個股分析 | K 線與均線、波動率、ESG 雷達圖、同業比較 |
| 模型解釋 | 特徵重要性、Rank IC、前 N 檔超額報酬、訓練紀錄 |
| 產業與籌碼 | 各產業近期報酬與趨勢、三大法人買賣超（僅供參考，不影響選股） |